



Fundação de Negócios,
Analytics e Tecnologia

Gym AI Agents

Atendimento Escalável com
Agentes de IA em uma
Academia Premium

Introdução

A MoveMais Academia é uma rede de academias premium com três unidades na região metropolitana de Campinas. Fundada há sete anos, a empresa consolidou sua reputação ao oferecer acompanhamento personalizado, equipe técnica qualificada e uma proposta de atendimento consultiva, diferente das academias tradicionais focadas em volume e baixo custo.

Nos últimos dois anos, a empresa tomou uma decisão estratégica relevante: centralizou seu atendimento no e-mail e ampliou a equipe de relacionamento para oferecer um canal mais estruturado e consultivo do que as redes sociais. Os primeiros resultados confirmaram a aposta. A taxa de conversão de novos alunos aumentou e a satisfação geral subiu.

O sucesso, porém, criou um novo problema. O volume de mensagens cresceu muito além da capacidade da equipe, e a diversidade dos temas tornou o gargalo ainda mais complexo: em uma mesma tarde chegavam e-mails de novos interessados, alunos querendo cancelar, outros com planos vencidos e dúvidas técnicas sobre treino e alimentação. Cada tipo de mensagem exigia conhecimento, tom e profundidade diferentes. A equipe não conseguia atender bem todos esses casos ao mesmo tempo.

Este case propõe o uso de Inteligência Artificial como resposta a esse desafio. O problema central é construir um ecossistema de cinco agentes especializados, integrado ao canal de e-mail da MoveMais, capaz de atender cada perfil de mensagem com precisão, em qualquer horário, sem comprometer a qualidade do atendimento nem gerar custos descontrolados.

Contexto da Empresa

A MoveMais Academia é uma rede de academias premium com três unidades na região metropolitana de Campinas. Fundada há sete anos, a empresa consolidou sua reputação ao fugir do modelo tradicional de academia por volume: enquanto a concorrência aposta em infraestrutura ampla e mensalidades baixas, a MoveMais investiu em acompanhamento personalizado, equipe técnica qualificada e uma experiência de treino diferenciada.

O portfólio de serviços inclui planos de musculação com ficha individualizada, aulas coletivas com capacidade limitada para garantir atenção do instrutor, assessoria nutricional com profissional próprio e programas de treino funcional para diferentes faixas etárias. Essa proposta de valor mais consultiva sempre exigiu um relacionamento próximo com os alunos, o que historicamente foi conduzido de forma presencial, na recepção de cada unidade.

Mudança Estratégica e Oportunidade:

Nos últimos dois anos, o setor de academias premium no Brasil passou por uma transformação relevante. A demanda por acompanhamento de saúde cresceu de forma consistente, e os consumidores passaram a pesquisar e contratar serviços de academia da mesma forma que contratam outros serviços digitais: comparando opções online, fazendo perguntas por mensagem e esperando respostas rápidas antes de tomar a decisão.

Identificando essa mudança de comportamento, a MoveMais tomou uma decisão estratégica: centralizar seu atendimento no e-mail, criando um canal mais estruturado e consultivo do que as redes sociais, e capaz de registrar o histórico completo de cada aluno. A equipe de relacionamento, até então focada no atendimento presencial, foi ampliada e passou a responder e-mails de forma dedicada. Os primeiros resultados confirmaram a aposta.

A taxa de conversão de leads aumentou, os índices de satisfação subiram e os alunos passaram a se engajar mais com a academia por meio das trocas realizadas por e-mail.

O Gargalo:

O sucesso da mudança criou um problema que a liderança não havia antecipado com clareza. O volume de mensagens cresceu em ritmo muito superior à capacidade da equipe de três pessoas responsável pelo relacionamento digital. Em períodos de alta demanda, como início de ano e início de semestre, a caixa de entrada acumulava dezenas de mensagens sem resposta por um ou dois dias. O problema não era apenas o volume. Era a diversidade dos temas. Em uma mesma tarde, a equipe recebia e-mails de pessoas interessadas em se matricular, alunos querendo cancelar o plano, outros perguntando sobre renovação, dúvidas técnicas sobre execução de exercícios e questões sobre alimentação pré e pós-treino.

Cada tipo de mensagem exigia um conhecimento diferente, um tom diferente e uma resposta com profundidade diferente.

Contratar mais pessoas para a equipe resolveria o volume, mas não resolveria a especialização. E aumentaria os custos fixos de forma considerável, especialmente nos períodos de menor demanda.

Em uma reunião, Carla Drummond, diretora de operações da MoveMais, encontrou a equipe de Thiago Melo, coordenador de relacionamento com o aluno, e todos estavam visivelmente sobrecarregados. A caixa de entrada compartilhada mostrava 53 e-mails sem resposta. Alguns aguardavam retorno há mais de dois dias.

"O problema não é só a quantidade", disse Thiago. "É que cada um desses e-mails precisa de uma resposta completamente diferente."

Carla fechou o notebook e ficou em silêncio por um momento.

"A gente está perdendo aluno para concorrente que responde em dez minutos. E os que ficam não estão recebendo o atendimento que prometemos quando se matricularam."

A conversa que se seguiu foi o ponto de partida para um projeto que a MoveMais decidiu colocar em prática: construir um ecossistema de agentes de inteligência artificial capaz de atender cada tipo de mensagem com o tom, o conhecimento e a profundidade adequados, a qualquer hora do dia, sem comprometer a qualidade da experiência do aluno.

A MoveMais contratou sua equipe para desenhar e implementar esse ecossistema.

O Desafio

O desafio consiste em construir uma única solução integrada: um ecossistema de cinco agentes especializados operando no e-mail. A construção envolve as frentes de trabalho descritas a seguir.

Agente de Vendas:

O primeiro agente a ser construído é o responsável pelo atendimento de novos leads. Ele deve conduzir uma conversa natural e consultiva, sem que o interessado perceba estar interagindo com um sistema automatizado. Por meio de perguntas contextualizadas e no ritmo certo, o agente deve extrair as informações essenciais para apresentar o plano mais adequado:

- Objetivo com a academia;
- Nível de experiência com treino;
- Disponibilidade de horários;
- Número de pessoas;
- Orçamento disponível.

A recomendação é construir e validar esse agente primeiro diretamente na interface do ChatGPT, Gemini ou Claude, por meio de engenharia de prompt, antes de integrá-lo ao ambiente de produção. Vale testar como ele reage a objeções do lead (preço, indecisão ou comparação com concorrente), para validar o comportamento conversacional e o tom antes de levá-lo para o N8N.

Integração via N8N com RAG:

A integração tem dois objetivos complementares, ambos executados dentro do N8N.

O primeiro é integrar o agente de vendas ao canal de e-mail da MoveMais utilizando o N8N como plataforma de automação de fluxos. O agente será conectado à caixa de entrada, monitorando mensagens recebidas e identificando contatos de pessoas interessadas em se matricular.

O segundo é construir um fluxo de ingestão que leia os arquivos de base de conhecimento da MoveMais — Planos e Preços, Protocolos de Treino e Guia Nutricional — e os carregue em um banco de dados vetorial (Supabase com pgvector), gerando os embeddings necessários para a recuperação semântica.

Com isso, o agente de vendas será aprimorado com a técnica de RAG (Retrieval-Augmented Generation), permitindo que suas respostas sejam fundamentadas nas informações reais da academia: planos disponíveis, preços, horários e diferenciais de cada unidade.

Ao final, o fluxo de ingestão dos arquivos e o agente de vendas integrado ao e-mail com RAG passam a operar de forma articulada dentro do N8N.

Ecosistema de Cinco Agentes:

O sistema se expande para um ecossistema completo, com os cinco agentes especializados operando de forma integrada no canal de e-mail da MoveMais:

a. Agente de Vendas:

Responsável pelo atendimento de novos leads.

Conduz uma conversa consultiva para identificar o perfil do interessado e apresentar o plano mais adequado, com base nas informações da base de conhecimento da academia.

b. Agente de Cancelamento:

Responsável por atender alunos que manifestaram intenção de encerrar o plano. Sua função é identificar o motivo real do cancelamento e propor alternativas adequadas, como congelamento, downgrade de plano ou pausa temporária, antes de processar a solicitação.

O agente só confirma o cancelamento quando todas as alternativas forem recusadas pelo aluno.

c. Agente de Renovação:

Responsável por reativar o relacionamento com alunos cujo plano está vencendo ou já venceu. Com base no histórico do aluno, conduz uma abordagem personalizada com condição especial de renovação, sem tom de cobrança e sem tratar o aluno como inadimplente.

d. Agente de Treinos:

Responsável por atender alunos ativos com dúvidas técnicas sobre exercícios, montagem de treino e progressão de carga. Antes de qualquer orientação, coleta informações sobre objetivo, dias disponíveis e limitações físicas. Não orienta alunos que relataram lesão sem recomendar avaliação presencial.

e. Agente de Nutrição:

Responsável por orientar alunos sobre alimentação aliada ao treino, suplementação básica e ajuste calórico por objetivo. Deixa claro que para um plano alimentar completo o aluno deve agendar consulta com a nutricionista da academia.

O desafio adicional desta fase é garantir que o sistema de roteamento seja capaz de identificar, a partir do conteúdo de cada e-mail, qual agente deve assumir o atendimento, evitando sobreposições e garantindo uma experiência coesa para o aluno.

Considerações

Ao longo das três fases, dois aspectos devem ser monitorados e gerenciados.

Gestão de custos:

Os agentes operam com modelos de linguagem que cobram por volume de tokens processados. É necessário calcular e otimizar o custo por atendimento, garantindo que a solução seja financeiramente viável para uma empresa de médio porte operando em escala. Agentes como o de Treinos e o de Nutrição tendem a gerar conversas mais longas e, portanto, mais custosas.

Estratégias como compressão de contexto, uso de modelos de menor custo para tarefas de classificação e definição de limites de consumo precisam ser consideradas.

Segurança da informação:

Os e-mails dos alunos contêm dados pessoais sensíveis, incluindo informações de saúde, histórico de pagamento e dados de contato. A solução deve contemplar boas práticas de privacidade, como controle de acesso às credenciais de APIs, restrição ao armazenamento de dados desnecessários e conformidade com a LGPD (Lei Geral de Proteção de Dados). Dados relacionados à saúde possuem classificação especial na LGPD e exigem atenção redobrada.

Perguntas para Discussão

1. Como estruturar o prompt do agente de vendas para que ele conduza uma conversa calorosa e consultiva, sem parecer um formulário ou um chatbot genérico?
2. Como deve ser construído o fluxo de ingestão no N8N para carregar os arquivos de base de conhecimento no Supabase? Quais etapas esse fluxo precisa executar, do carregamento do arquivo à geração dos embeddings?
3. O agente de Cancelamento e o agente de Renovação lidam com situações próximas, mas precisam de abordagens completamente diferentes. Como o sistema de roteamento deve distinguir os dois casos, e como o comportamento de cada agente deve ser moldado para refletir essa diferença?

4. Onde está o limite de atuação dos agentes de Treinos e de Nutrição? Defina quais tipos de perguntas cada agente pode responder de forma autônoma e em quais situações ele deve escalar o atendimento para um profissional humano.
5. Como calcular o custo estimado por atendimento do ecossistema completo? Considere que agentes diferentes geram conversas de comprimentos diferentes e que o orquestrador também consome tokens a cada interação.

Critérios de Avaliação

O trabalho será avaliado conforme a rubrica abaixo, com nota máxima de 10 pontos:

FASE	CRITÉRIOS	PESO
Prompt Engineering – Agente de Vendas	- O prompt define uma persona com nome, tom e função? - O agente coleta as informações em sequência natural, sem listar tudo de uma vez? - Os exemplos de conversa demonstram comportamento adequado, incluindo ao menos um cenário de objeção ou resistência?	2,5
Integração N8N com RAG	- O fluxo de ingestão carrega os três arquivos e gera embeddings com chunks e overlap adequados? - O agente de vendas consulta o RAG e retorna informações precisas da base (preços, planos, horários)? - O fluxo responde corretamente ao e-mail de origem?	2,5

FASE	CRITÉRIOS	PESO
Ecosistema de Cinco Agentes	- O sistema de roteamento identifica corretamente o agente responsável para cada tipo de mensagem? - Cada agente mantém o tom e o escopo adequados ao seu papel? - Os agentes de Treinos e Nutrição respeitam os limites de atuação (sem prescrição dietética individualizada, sem orientar alunos com lesão sem encaminhar para avaliação)? - O agente de Cancelamento propõe alternativas antes de confirmar o cancelamento?	2,5
Perguntas de Discussão	- As respostas demonstram compreensão dos conceitos (RAG, roteamento, custo, limites de atuação)? - O raciocínio é fundamentado em exemplos concretos da realidade do negócio?	2,5

Entregáveis

1. **Arquivo .docx** com o prompt (System Message) de todos os cinco agentes do ecossistema (Vendas, Cancelamento, Renovação, Treinos e Nutrição), com as escolhas de design de cada um.
2. **Arquivo .json do n8n:** o fluxo completo e funcional exportado em JSON, contemplando a ingestão da base de conhecimento no Supabase (RAG) e o ecossistema dos cinco agentes com o sistema de roteamento, integrado ao canal de e-mail. Todas as credenciais e identificadores de ambiente substituídos por placeholders.
3. **Arquivo .docx** de até 5 páginas com as respostas das perguntas de discussão e ao menos três exemplos de interações reais com os agentes, incluindo o e-mail enviado para teste e a resposta gerada, que demonstrem o comportamento esperado do ecossistema.

Atenção – Credenciais:

Antes de exportar e compartilhar qualquer arquivo JSON do N8N, substitua por placeholders todas as informações que identifiquem seu ambiente real. Isso inclui chaves de API (`[SUA_OPENAI_API_KEY]`), tokens OAuth (`[TOKEN_GMAIL]`), URLs de serviços (`[URL_SUPABASE]`), IDs de pastas do Google Drive (`[ID_PASTA_RAG]`), nomes de índices vetoriais (`[NOME_INDICE_PINECONE]`) e o instance ID do N8N presente no campo `meta.instanceId` do JSON.

O envio de qualquer identificador real em arquivos compartilhados permite que terceiros localizem ou acessem seus recursos.

FAQ

Dúvidas Técnicas:

1. Como instalo e configuro o n8n?

O n8n pode ser executado de duas formas: localmente via npx (npx n8n) ou via n8n Cloud. Para o local, instale o Node.js 18+, abra o terminal e execute npx n8n. A interface abre em <http://localhost:5678>. Se preferir não deixar o terminal aberto, use o n8n Cloud, que tem um plano gratuito com limite de execuções, suficiente para desenvolver e testar o case.

2. Como conecto o Gmail ao n8n?

Use o node "Gmail Trigger" ou "Email Trigger (IMAP)". Para o Gmail com OAuth, crie uma credencial do tipo Google OAuth2 nas configurações do n8n, o que exige configurar um projeto no Google Cloud Console, habilitar a Gmail API e gerar as credenciais OAuth (o processo está na documentação oficial do n8n). Alternativa mais simples: usar o protocolo IMAP com uma senha de app do Google (Conta Google > Segurança > Verificação em duas etapas > Senhas de app). É menos elegante, mas funciona sem configurar o Google Cloud.

3. Como configuro a API Key da OpenAI no n8n?

Crie uma credencial do tipo "OpenAI API" e cole a chave no campo correspondente. Ela é usada pelos nodes de LLM (OpenAI Chat Model). Para o Gemini, use a credencial "Google Gemini API" com a chave do Google AI Studio. Nunca coloque a API Key diretamente em campos de texto dos nodes: use sempre o sistema de credenciais do n8n, que criptografa a chave e não a expõe no JSON exportado.

4. Como configuro o Supabase para o RAG?

- Crie uma conta gratuita em supabase.com e crie um projeto;
- No SQL Editor do Supabase, habilite a extensão pgvector: `CREATE EXTENSION IF NOT EXISTS vector;`
- Crie a tabela de documentos com o schema recomendado pelo n8n (o node Supabase Vector Store traz a documentação com o SQL exato);
- Obtenha a URL do projeto e a service_role key nas configurações do Supabase;
- No n8n, crie a credencial Supabase com essas informações.

Para popular o RAG com os arquivos do case (Planos e Preços, Protocolos de Treino, Guia Nutricional), use o fluxo de ingestão de documentos: ler o arquivo, passar pelo node de embeddings (OpenAI Embeddings) e salvar no Supabase Vector Store.

5. O workflow é acionado, mas o agente não responde ao e-mail. Como diagnosticar?

Verifique nesta ordem: (1) o node de "Send Email" ou "Gmail: Send" está conectado corretamente? (2) o endereço de destino está sendo lido do trigger (geralmente `{{ $json.from }}`)? (3) há algum node retornando erro entre o LLM e o envio? Ative o modo de debug no n8n e veja qual node falha. (4) a resposta do LLM está sendo extraída corretamente? O campo costuma ser `{{ $json.message.content }}` ou similar, dependendo do node.

6. Exportei o JSON do n8n, mas ao importar em outra máquina as credenciais não aparecem. Isso é erro?

Não, é o comportamento esperado e correto. As credenciais (API Keys, OAuth) não são exportadas com o JSON por segurança. Ao importar, o n8n indica os nodes com credenciais faltando. Você precisa recriar as credenciais na nova instância e vinculá-las manualmente. Vale lembrar disso no entregável: o JSON é o fluxo lógico e não inclui credenciais.

7. Por que a Fase 1 pede para construir o agente no ChatGPT, Gemini ou Claude e não direto no n8n?

Testar o comportamento do agente em uma interface conversacional é mais rápido do que depurar dentro de um fluxo n8n. Erros de prompt (tom robótico, perguntas em lista, sequência inadequada de coleta) são muito mais fáceis de identificar e corrigir conversando direto com o modelo. A Fase 1 é deliberadamente simples para você validar a lógica e o tom do agente antes de lidar com a complexidade da integração no n8n.

8. O que são placeholders de credenciais e como aplicá-los antes de entregar o JSON?

Ao exportar um fluxo, as credenciais vinculadas não vão no JSON, mas alguns nodes têm campos de texto (URLs de endpoint, nomes de tabela e outros parâmetros) preenchidos manualmente que podem conter dados sensíveis. Antes de entregar, abra o JSON em um editor de texto e substitua qualquer dado real por um texto descritivo entre colchetes, por exemplo: [SUA_OPENAI_API_KEY], [URL_DO_SUPABASE], [TOKEN_GMAIL]. Assim o arquivo pode ser compartilhado com segurança, sem expor contas ou serviços reais.

Dúvidas Conceituais:

1. O que é um agente de IA e qual a diferença para um chatbot simples?

Um chatbot simples segue um fluxo fixo de perguntas e respostas pré-definidas. Um agente de IA usa um modelo de linguagem que compreende contexto e gera respostas dinâmicas. Na prática: o chatbot só responde o que foi programado; o agente entende uma pergunta não prevista e formula uma resposta adequada. No case, o agente de Treinos consegue responder variações infinitas de dúvidas sobre exercícios sem que todas tenham sido antecipadas.

2. O que é RAG e por que os arquivos da MoveMais precisam dele?

RAG (Retrieval-Augmented Generation) é a técnica de recuperar informações relevantes de uma base de conhecimento antes de gerar a resposta. Sem RAG, o agente usa apenas o conhecimento geral do modelo, que não sabe os preços da MoveMais, os planos disponíveis nem os protocolos de treino específicos. Com RAG, quando um lead pergunta sobre preços, o sistema busca o trecho relevante do arquivo "Planos e Preços MoveMais" e o inclui no prompt, permitindo uma resposta precisa e fundamentada.

3. O que é temperatura em um modelo de linguagem?

Temperatura é um parâmetro que controla o grau de "criatividade" das respostas. Temperatura 0 produz respostas mais determinísticas e consistentes (boa para classificação e respostas factuais). Temperatura 1 ou acima produz respostas mais variadas. Para o agente de Vendas, uma temperatura entre 0.6 e 0.8 equilibra naturalidade e consistência. Para o agente de Treinos, temperaturas mais baixas (0.3 a 0.5) deixam as orientações técnicas mais estáveis.

4. Qual é o limite do agente de Nutrição? Ele pode prescrever dietas?

Não. O agente de Nutrição orienta sobre alimentação geral aliada ao treino (macros, timing de refeições, suplementação básica), mas não pode prescrever plano alimentar individualizado, calcular necessidades calóricas específicas por patologia ou substituir a consulta com a nutricionista. O CFN (Conselho Federal de Nutrição) define a prescrição dietética como ato privativo do nutricionista. O agente deve orientar e encaminhar para agendamento quando a dúvida ultrapassar a orientação geral.

5. O agente de Cancelamento deve convencer o aluno a não cancelar? Isso não é antiético?

Há uma distinção importante: o agente deve oferecer alternativas genuínas (congelamento, pausa, downgrade) que podem resolver o problema real do aluno, e não usar persuasão manipulativa para manter uma assinatura que o prejudica. Se o aluno disse que vai mudar de cidade, oferecer um mês grátis é antiético. Se ele disse que está sem tempo, sugerir um plano de 2 dias por semana é legítimo. O prompt deve deixar clara essa distinção de postura.

Testes e Validação:

1. Como testar se o roteamento entre os cinco agentes está funcionando?

Crie uma bateria de e-mails de teste que misture intenções: um claramente de lead, um de cancelamento, um de renovação, um com dúvida de treino e um com dúvida de nutrição. Envie cada um e verifique qual agente foi ativado. Teste também casos ambíguos (por exemplo, "quero cancelar porque não estou vendo resultado", que pode ir para Cancelamento ou Treinos). O comportamento esperado nesses casos deve estar previsto no design do seu orquestrador.

2. Como saber se a base RAG está sendo consultada corretamente?

Faça uma pergunta que só pode ser respondida com a base (por exemplo, o preço exato de um plano). Se o agente responde com o valor correto, o RAG está funcionando. Se ele inventa um valor ou diz que não tem a informação, há um problema na recuperação. Verifique: (1) os documentos foram carregados no Supabase? (2) o modelo de embeddings usado na ingestão é o mesmo usado na busca? (3) o número de chunks retornados (topK) é suficiente para cobrir a resposta?

3. O agente de Treinos orientou um aluno com dor nas costas a continuar treinando. É problema de prompt?

Sim. Essa situação deve ser tratada explicitamente no prompt. O agente precisa perguntar sobre limitações físicas antes de qualquer orientação e, ao identificar dor ou lesão, encaminhar para avaliação presencial sem sugerir treinos até que o aluno seja liberado por um profissional. Uma instrução útil no prompt: "Nunca oriente exercícios para alunos que relataram dor, lesão ou restrição médica sem antes recomendar avaliação com o educador físico da academia."

4. Como estimar o custo por atendimento do ecossistema?

Estime o custo de uma conversa específica que você teve com o agente durante os testes: quantos turnos? Quantas palavras por turno? Lembre que o orquestrador também consome tokens para classificar cada e-mail antes de acionar o agente. Multiplique a estimativa de tokens pelo preço do modelo escolhido e projete para o volume mensal esperado. Modelos menores para a etapa de classificação ajudam a reduzir o custo.

Outras Dúvidas:

1. Em termos de avaliação, precisa consultar uma base pra ver se o cliente já é cliente mesmo ou não?

Pra avaliação não, pois adicionaria mais etapas no fluxo. Na vida real sim, se você for fazer uma interação com alguma pessoa, uma das primeiras coisas é consultar se a pessoa já está na base, pois assim você pode direcionar pra algum outro agente específico mais rapidamente. Seja pra contratação, renovação ou cancelamento.

2. Em termos de avaliação, precisa consultar uma base pra ver os descontos dos planos?

Em termos de avaliação não, você pode deixar no prompt do agente (system message).